

Proyecto Integrador M1 · Conociendo al cliente 360°

Estudiante: Tomás Babot · **Programa:** Data Science, Soy Henry (cohorte DSPT12) · **Ciudad analizada:** Chicago

1. De qué trata el proyecto

InsightReach es una empresa de marketing digital que diseña campañas personalizadas para negocios locales. Para mejorar su segmentación recibimos una base de **30.000 clientes de restaurantes de 10 ciudades de EE. UU.** El objetivo es limpiarla, explorarla, enriquecerla con datos de mercado de la **API de Yelp** y convertirla en **recomendaciones de segmentación** accionables.

El análisis se enfoca en **Chicago** (5.384 clientes, la ciudad más grande de la base y la que se cruza con Yelp) y busca responder, además de lo básico, preguntas menos obvias: si la preferencia alimenticia se relaciona con el estrato, qué variables se relacionan realmente entre sí, si la oferta de Chicago cubre lo que los clientes pueden pagar y dónde está el potencial de crecimiento.

2. Estructura del repositorio

El repositorio tiene tres carpetas:

Carpeta	Archivo	Qué contiene
Avances/	Avance_EDA.ipynb	Avance 1 (EDA) y Avance 3 (análisis y recomendaciones)
Avances/	Avance_API_Yelp.ipynb	Avance 2 (API de Yelp e integración con los clientes)
Documentacion/	README.pdf	Este documento
Documentacion/	Recomendaciones.pdf	Propuestas de segmentación para el equipo comercial
data/	base_datos_restaurantes_USA_v2.csv	Base original de clientes (provista por el curso)
data/	yelp_restaurantes_chicago.csv	Restaurantes de Chicago descargados de la API de Yelp

Carpeta	Archivo	Qué contiene
data/	base_unificada_chicago.csv	Clientes de Chicago limpios + información de Yelp (Avance 2)

3. Cómo reproducir el análisis

1. Instalar las librerías: `pip install pandas numpy matplotlib seaborn scipy requests jupyter`
2. Abrir Jupyter y ejecutar los notebooks de la carpeta `Avances/`, de arriba hacia abajo. El orden lógico es: **Avance 1** (`Avance_EDA.ipynb` , secciones 1 a 7) con la base de clientes; **Avance 2** (`Avance_API_Yelp.ipynb`) con la API de Yelp, que **junta las dos fuentes** y guarda `data/base_unificada_chicago.csv` ; y **Avance 3** (`Avance_EDA.ipynb` , secciones 8 a 10), que **parte de esa base unificada**. Como la base unificada ya está guardada en `data/` , cada notebook también corre por separado.
3. **API de Yelp (opcional)**: sin clave, el notebook lee `data/yelp_restaurantes_chicago.csv` , que contiene una respuesta real de la API guardada, así que todo es reproducible. Para hacer la consulta en vivo (y actualizar ese CSV), definir en la terminal la variable de entorno con una clave propia: `export YELP_API_KEY="tu_clave"` .

La clave de Yelp **nunca** se escribe en el código ni se sube al repositorio.

4. Qué se hizo en cada avance

Avance 1 · Carga, filtrado, limpieza y tabulación (`Avance_EDA.ipynb`)

- **Carga y filtrado**: se cargó la base completa y se filtró **Chicago**, elegida por ser la ciudad con más clientes (17,9%) y la que se cruza con Yelp.
- **Limpieza documentada**:
 - *Nulos*: teléfono y correo (~50%) se descartaron; `preferencias_alimenticias` (5%) pasó a la categoría explícita `Sin dato` ; edad y gasto se imputaron con la mediana.
 - *Duplicados*: no hay filas duplicadas ni `id_persona` repetidos; los 3 pares de homónimos son personas distintas; hay 14 correos repetidos (no se usan).
 - *Errores*: 29 edades imposibles (-5 y 300) y 286 frecuencias de visita negativas (-3). Se pasaron a nulos y se imputaron con la mediana. El gasto 0 (261 clientes) **no** es un error: coincide exactamente con frecuencia de visita 0.
 - *Tipos de dato y datos personales*: se revisaron los tipos antes y después; nombre, apellido, teléfono y correo se eliminaron de la base de trabajo.

- **Tablas y estadística descriptiva:** frecuencias, tablas cruzadas, tendencia central, dispersión y forma; y 7 tipos de gráficos exploratorios.

Avance 2 · API de Yelp e integración (Avance_API_Yelp.ipynb)

- Conexión al endpoint `businesses/search` con paginación (240 restaurantes de Chicago) y autenticación por *token*; el resultado se aplanar y se guarda en `data/yelp_restaurantes_chicago.csv` .
- Control de calidad (sin duplicados ni cerrados; 40% sin precio) y exploración: ratings altos y parejos, oferta concentrada en `$$` y en bares (43%). Se estudió además si los más populares son los mejor calificados y se identificaron las **"joyas ocultas"** (restaurantes con excelente rating y poca visibilidad).
- **Integración:** como no hay un identificador común, se cruzó por **tipo de comida**: se agruparon las preferencias de los clientes y las categorías de Yelp en 4 grupos (Carnes, Mariscos y pescado, Vegetariano/Vegano, Otro) y se unieron con `pd.merge` . Se agregó un análisis de sensibilidad sobre la definición vegetariana.
- **Salidas:** `data/yelp_restaurantes_chicago.csv` y `data/base_unificada_chicago.csv` (cada cliente con la información de Yelp de su preferencia).


Avance 3 · Análisis, interpretación y recomendaciones (Avance_EDA.ipynb , secciones 8 a 10)

Parte de la **base unificada** del Avance 2 (clientes limpios + Yelp) y responde ocho preguntas de negocio con tablas, gráficos y pruebas estadísticas:

#	Pregunta
P1	¿Qué características distinguen a los clientes que más gastan?
P2	¿La preferencia alimenticia se relaciona con el estrato?
P3	¿Qué variables están relacionadas entre sí? (mapa de asociaciones)
P4	¿Quién consume licor?
P5	¿La oferta cubre lo que los clientes prefieren comer?
P6	¿La oferta cubre lo que los clientes pueden pagar?
P7	¿Cómo segmentamos por valor y cómo es cada segmento?
P8	¿Dónde está el potencial de crecimiento?

- **Salida:** los grupos, el índice de valor y los segmentos se calculan en el notebook (la base final queda en memoria). La sección 9 incluye **un gráfico que respalda cada una de las 9 recomendaciones**. El documento completo está en `Recomendaciones.pdf` .


5. Resultados principales



Cientes por ciudad (Avance_EDA.ipynb, sección 3): Chicago es la ciudad con más clientes.



Mapa de asociaciones entre variables (Avance_EDA.ipynb, P3): solo estrato–membresía y edad–licor se relacionan.



Clientes por restaurante afín de Yelp (Avance_API_Yelp.ipynb, sección 6.7).

#	Hallazgo	Evidencia
1	La preferencia alimenticia y el estrato no se relacionan.	V de Cramér = 0,026; chi-cuadrado p = 0,90. Todos los estratos tienen casi la misma mezcla de preferencias.
2	El 24% de los clientes genera el 66% del valor.	Segmento Alto valor: 1.281 clientes, ingreso medio de \$10.247, 85% con membresía premium.
3	El valor lo define el estrato; la membresía premium solo lo refleja.	Mediana de gasto por visita: \$6,86 (Bajo), \$17,65 (Medio), \$32,61 (Alto), \$53,09 (Muy Alto). Dentro de cada estrato premium y no premium gastan igual (p = 0,68; 0,83; 0,23).
4	Vegetarianos y veganos: el mayor grupo, casi sin oferta.	31,5% de los clientes vs. 2 de 240 restaurantes (0,8%): 847 clientes por restaurante.
5	Brecha de precio.	El 28% de los clientes gasta hasta \$10 por visita; solo 1 de los 144 restaurantes con precio (0,7%) es \$.
6	El licor depende de la edad, no del estrato.	90% de consumo entre 18 y 30 años vs. 55% en los demás (V = 0,34); por estrato, 62-63% en todos (p = 0,69).

#	Hallazgo	Evidencia
7	Potencial de crecimiento en los ocasionales de alto gasto.	957 clientes que gastan \$33 por visita pero visitan 3,6 veces (embajadores: 6,4). Igualar esa frecuencia sumaría ~12% al valor.
8	"Joyas ocultas" en Yelp.	El rating baja al subir las reseñas (correlación de -0,38, con las reseñas en escala logarítmica); 24 restaurantes con rating de 4,6 o más y poca visibilidad.
9	Género, medio de pago y ocio no se relacionan con nada.	V de Cramér menor a 0,05 con todas las demás variables.

6. Decisiones y supuestos importantes

- **Mediana en lugar de media** para imputar: gasto e ingresos son asimétricos.
- **No se eliminaron outliers de gasto e ingresos:** son clientes reales de alto valor.
- **Índice de valor = gasto × frecuencia:** es relativo (no conocemos la unidad de la frecuencia), sirve para ordenar clientes pero no equivale a dólares.
- **El cruce clientes-Yelp es por tipo de comida** y por eso es una aproximación (ver limitaciones).
- **Rangos de precio de Yelp** usados como referencia: \$ hasta 10 USD, \$\$ de 11 a 30, \$\$\$ de 31 a 60, \$\$\$\$ más de 60 (aproximados).
- **Joyas ocultas:** rating de 4,6 o más, al menos 30 reseñas (para que la nota sea confiable) y menos reseñas que la mediana.

7. Limitaciones

- Los 240 restaurantes son el 3% de los 7.900 que Yelp registra, ordenados por relevancia: favorecen a los locales populares y subrepresentan a los baratos (solo 1 figura como \$).
- Las categorías de Yelp describen el negocio, no el menú, y los rangos de precio son aproximados.
- Se asume que los clientes comen en la ciudad donde viven.
- Los datos de clientes son sintéticos (provistos por el curso): algunas relaciones son más limpias que en datos reales (por ejemplo, el salto del consumo de licor entre los 30 y 31 años).
- El escenario de crecimiento es una simulación, no una predicción.

8. Extra credits

- **Técnicas estadísticas:** pruebas de Kruskal-Wallis y chi-cuadrado, V de Cramér y mapa de asociaciones entre todas las variables categóricas; análisis de confusión (membresía vs. estrato); análisis de sensibilidad de la definición vegetariana; escenario de crecimiento.
- **Automatización:** la ciudad (CIUDAD) y la clave de Yelp (YELP_API_KEY) se definen en un solo lugar, la descarga de Yelp es una función (descargar_negocios) y cada notebook corre completo de arriba hacia abajo sin pasos manuales; el de Yelp guarda la base unificada en CSV.