

Proyecto Integrador M1 · Conociendo al cliente 360°

Estudiante: Tomás Babot

Programa: Data Science, Soy Henry (cohorte DSPT12)

Ciudad analizada: Chicago

Repositorio: github.com/babottomas561-cell/ProyectoM1_TomasBabot

Índice

1. Resumen del proyecto
2. Estructura del repositorio
3. Datos utilizados
4. Cómo reproducir el análisis
5. Avance 1 · Carga, filtrado, limpieza y tabulación
6. Avance 2 · API de Yelp e integración
7. Avance 3 · Análisis, interpretación y recomendaciones
8. Resultados principales
9. Decisiones y supuestos
10. Limitaciones
11. Extra credits
12. Cumplimiento de la consigna
13. Glosario

1. Resumen del proyecto

Contexto

InsightReach es una empresa de marketing digital que diseña campañas personalizadas para negocios locales. Con el crecimiento de su base de clientes quiere segmentarlos mejor para que sus campañas sean más efectivas. Para eso recibimos una base de 30.000 clientes de restaurantes de 10 ciudades de EE. UU., en el rol de Científico de Datos Junior.

Objetivo

Limpiar y explorar la base de clientes, enriquecerla con datos de mercado obtenidos de la API de Yelp y convertir el análisis en recomendaciones de segmentación que el equipo comercial pueda aplicar.

Alcance

El análisis se enfoca en Chicago: 5.384 clientes (la ciudad más grande de la base) y 240 restaurantes de Yelp. Además de describir a los clientes, buscamos responder preguntas de negocio: qué distingue a quienes más gastan, si la preferencia alimenticia depende del estrato, si la oferta de la ciudad cubre lo que los clientes quieren comer y pueden pagar, y dónde está el potencial de crecimiento.

Resultado en pocas líneas

- El valor de un cliente lo define su nivel socioeconómico; la preferencia alimenticia es independiente. Por eso proponemos segmentar en dos ejes: el estrato para decidir cuánto invertir y la preferencia para decidir qué ofrecer.
- El 24% de los clientes (segmento Alto valor) genera el 66% del valor.
- El grupo vegetariano y vegano es el más grande (31,5%) y casi no tiene oferta en Yelp (2 de 240 restaurantes).
- Hay 957 clientes con presupuesto que visitan poco: si visitaran como los mejores clientes, el valor total subiría cerca de un 12%.
- Las 9 recomendaciones, con su plan de implementación, están en Recomendaciones.pdf.

2. Estructura del repositorio

El repositorio tiene tres carpetas y dos archivos de configuración:

Carpeta	Archivo	Qué contiene
Avances/	Avance_EDA.ipynb	Avance 1 (carga, limpieza, tablas y EDA, secciones 1 a 7) y Avance 3 (análisis y recomendaciones, secciones 8 a 10)
Avances/	Avance_API_Yelp.ipynb	Avance 2 (conexión a la API de Yelp e integración con los clientes)
Documentacion/	README.pdf	Este documento: pasos, resultados y decisiones
Documentacion/	Recomendaciones.pdf	Propuestas de segmentación para el equipo comercial
data/	base_datos_restaurantes_USA_v2.csv	Base original de clientes (provista por el curso)
data/	yelp_restaurantes_chicago.csv	Restaurantes de Chicago descargados de la API de Yelp
data/	base_unificada_chicago.csv	Cientes de Chicago limpios más la información de Yelp (salida del Avance 2)

Carpeta	Archivo	Qué contiene
(carpeta principal)	.env.example	Modelo para configurar la clave de Yelp (sin la clave)
(carpeta principal)	.gitignore	Lista de archivos que git no sube, entre ellos el .env con la clave

Los dos notebooks tienen la misma estructura en cada paso: qué hacemos y por qué, el código, el resultado y una interpretación.

3. Datos utilizados

Base de clientes (provista por el curso)

30.000 clientes y 17 columnas. Las variables que usamos en el análisis son:

Variable	Tipo	Significado
id_persona	Identificador	Código único del cliente
edad	Numérica	Edad en años
genero	Categórica	Femenino o Masculino
ciudad_residencia	Categórica	Una de las 10 ciudades de la base
estrato_socioeconomico	Categórica ordinal	Bajo, Medio, Alto o Muy Alto
frecuencia_visita	Numérica	Cantidad de visitas a restaurantes (escala de 0 a 10)
promedio_gasto_comida	Numérica	Gasto promedio por visita (USD)
ingresos_mensuales	Numérica	Ingreso mensual (USD)
preferencias_alimenticias	Categórica	Carnes, Mariscos, Pescado, Vegetariano, Vegano u Otro
consume_licor, ocio, membresia_premium	Categóricas (Sí/No)	Hábitos y suscripción
tipo_de_pago_mas_usado	Categórica	Efectivo, Tarjeta, App o Criptomoneda

Las otras cuatro columnas (nombre, apellido, teléfono y correo) son datos personales que no aportan al análisis y se eliminaron de la base de trabajo.

Restaurantes de Yelp (API)

240 restaurantes de Chicago descargados el 24/09/2026 del endpoint businesses/search de Yelp Fusion. Para cada uno guardamos 13 columnas: identificador, nombre, rating, cantidad de reseñas, precio, ciudad, código postal,

latitud, longitud, categorías (en texto y en códigos de Yelp), si hace delivery y si está cerrado.

Base unificada (salida del Avance 2)

Los 5.384 clientes limpios de Chicago con 18 columnas: las 13 de la base de trabajo, el grupo de preferencia y 4 columnas de Yelp sobre la oferta afín a su preferencia (cantidad de restaurantes, rating promedio, clientes por restaurante e índice de cobertura).

4. Cómo reproducir el análisis

1. Instalar las librerías: `pip install pandas numpy matplotlib seaborn scipy requests python-dotenv jupyter`
2. Abrir Jupyter y ejecutar los notebooks de la carpeta Avances/ de arriba hacia abajo (Run All).
3. Orden lógico: Avance 1 (Avance_EDA.ipynb, secciones 1 a 7); Avance 2 (Avance_API_Yelp.ipynb), que junta las dos fuentes y guarda `data/base_unificada_chicago.csv`; y Avance 3 (Avance_EDA.ipynb, secciones 8 a 10), que parte de esa base unificada. Como la base unificada ya está guardada en `data/`, cada notebook también corre por separado.
4. API de Yelp (opcional): sin clave, el notebook lee `data/yelp_restaurantes_chicago.csv`, que tiene una respuesta real de la API guardada, así que todo se puede reproducir. Para consultar la API en vivo: copiar `.env.example` con el nombre `.env` y pegar la clave de Yelp después de `YELP_API_KEY=`. Para reemplazar la descarga guardada por una nueva, cambiar `ACTUALIZAR_CSV = True`.

Cómo se maneja la clave de la API

La clave de una API es como una contraseña: si se publica, cualquiera puede usarla a nuestro nombre. Por eso nunca se escribe en el código ni se sube a GitHub. Se guarda en un archivo `.env` que queda solo en la computadora de quien corre el notebook, y el archivo `.gitignore` le indica a git que no lo suba. El notebook la carga con la librería `python-dotenv` (`load_dotenv`) y la lee con `os.getenv('YELP_API_KEY')`. El archivo `.env.example` muestra cómo configurarlo sin exponer ninguna clave.

Los dos notebooks se ejecutaron completos con Jupyter de arriba hacia abajo sin errores, con y sin el archivo `.env`.

5. Avance 1 · Carga, filtrado, limpieza y tabulación

Notebook: `Avance_EDA.ipynb`, secciones 1 a 7.

5.1 Carga y exploración

Cargamos el CSV con pandas y revisamos tamaño, tipos de dato y un resumen estadístico. A simple vista ya aparecían problemas de calidad: edades de -5 y 300 y frecuencias de visita negativas.

5.2 Filtrado por ciudad

Contamos los clientes por ciudad con `groupby` y elegimos **Chicago**, por dos motivos: es la ciudad con más clientes (5.384, el 17,9% de la base), lo que da

muestras más grandes en cada segmento, y tiene mucha oferta en Yelp para el cruce del Avance 2. Las campañas de InsightReach son locales, así que tiene sentido analizar una ciudad a la vez.

5.3 Limpieza

Primero detectamos los problemas, después los tratamos con un criterio explícito y al final verificamos el resultado.

Problema	Qué encontramos	Decisión y justificación
Nulos en teléfono y correo	~50% de nulos	Se eliminan: no aportan al análisis y son datos personales.
Nulos en preferencia alimenticia	268 clientes (5%)	Pasan a la categoría Sin dato: no inventamos una preferencia.
Nulos en edad y gasto	23 y 35 clientes	Se imputan con la mediana, que no se ve afectada por valores extremos.
Edades imposibles	29 clientes con -5 o 300	Pasan a nulo y se imputan con la mediana.
Frecuencias negativas	286 clientes con -3	Pasan a nulo y se imputan con la mediana.
Gasto igual a 0	261 clientes	Se conserva: son exactamente los 261 con frecuencia 0, clientes que no visitan.
Duplicados	Ninguna fila ni id repetido; 3 pares de homónimos; 14 correos repetidos	No se elimina nada: los homónimos son personas distintas y el correo no se usa.
Valores altos de gasto e ingresos	Aparecen como atípicos en los boxplots	Se conservan: son clientes reales de alto poder adquisitivo.
Cientes sin ningún dato de contacto	1.359 clientes (25%) sin correo ni teléfono	Se informa: no afecta el análisis, pero limita las campañas directas y se tiene en cuenta en las recomendaciones.

Resultado: una base sin nulos, con 5.384 clientes y 13 columnas, rangos válidos (edad entre 18 y 80, frecuencia entre 0 y 10) y tipos de dato correctos (edad y frecuencia pasan a enteros). Las medias casi no cambian, salvo la de frecuencia, que sube de 3,82 a 4,20 al desaparecer los -3.

5.4 Tabulación y estadística descriptiva

- **Tablas de frecuencia** de género, preferencias alimenticias, consumo de licor, estrato, ocio, membresía y medio de pago. Por ejemplo: género 50/50, el 62,7% consume licor, y vegetarianos (20,9%) más veganos (10,6%) suman el 31,5%, el grupo de preferencia más grande.

- **Tablas cruzadas:** licor por estrato (62-63% en todos), preferencia por género (casi igual) y membresía por estrato (de 0,7% en Bajo a 95,3% en Muy Alto).
- **Estadística descriptiva:** media, mediana, moda, desvío, rango, asimetría, curtosis y coeficiente de variación. Gasto e ingresos son asimétricos a la derecha, por eso usamos la mediana para describir al cliente típico.
- **Visualizaciones:** histogramas, countplots, boxplots, mapa de correlación, scatterplot de ingresos contra gasto y comparación del gasto por estrato y por preferencia. Cada gráfico tiene su interpretación en el notebook.

6. Avance 2 · API de Yelp e integración

Notebook: Avance_API_Yelp.ipynb.

6.1 Conexión y extracción

Nos conectamos al endpoint businesses/search de Yelp Fusion con autenticación por token (encabezado Authorization: Bearer). La clave se lee de un archivo .env que no se sube al repositorio (ver la sección 4). Como Yelp devuelve 50 resultados por página, la función descargar_negocios pagina con el parámetro offset hasta juntar 240 restaurantes. La respuesta es un JSON anidado, que aplanamos con pd.json_normalize para extraer nombre, categoría, rating, cantidad de reseñas, precio, ubicación, delivery y estado. La conexión en vivo devolvió el código 200 (correcto) en todas las páginas.

6.2 Control de calidad y exploración

- Sin duplicados, ratings válidos (entre 1 y 5) y ningún restaurante cerrado. El único faltante es el precio: 96 restaurantes (40%) no lo informan.
- Los ratings son altos y parejos (media de 4,38). La oferta se concentra en el rango \$\$ (93 restaurantes) y en bares: 103 restaurantes (43%) tienen una categoría de bar.
- Los más populares no son los mejor calificados: la correlación entre rating y reseñas es -0,38. Identificamos 24 "joyas ocultas": rating de 4,6 o más, al menos 30 reseñas y menos reseñas que la mediana.

6.3 Integración con los clientes

Las dos tablas no comparten un identificador (la base de clientes no dice a qué restaurante va cada uno), así que las cruzamos por un atributo común: el **tipo de comida**. Definimos 4 grupos que existen de los dos lados:

Grupo	Preferencias del cliente	Categorías de Yelp afines
Carnes	Carnes	Steakhouses, Barbeque, Burgers, Hot Dogs, Chicken Wings, Chicken Shop, Butcher
Mariscos y pescado	Mariscos, Pescado	Seafood, Sushi Bars, Fish & Chips, Poke
Vegetariano/Vegano	Vegetariano, Vegano	Vegetarian, Vegan

Grupo	Preferencias del cliente	Categorías de Yelp afines
Otro	Otro	Los restaurantes que no encajan en los anteriores

Para cada grupo calculamos la oferta (restaurantes, rating promedio, clientes por restaurante e índice de cobertura) y la unimos a cada cliente con `pd.merge (left join por grupo de preferencia)`. La base unificada conserva los 5.384 clientes, sin perder ni duplicar ninguno. Un análisis de sensibilidad con una definición vegetariana más amplia (que suma ensaladas, falafel y sin gluten) confirma el hallazgo principal: la oferta pasa de 2 a 9 restaurantes, frente a un 31,5% de clientes.

7. Avance 3 · Análisis, interpretación y recomendaciones


Notebook: Avance_EDA.ipynb, secciones 8 a 10. Parte de la base unificada del Avance 2 y responde ocho preguntas de negocio con tablas, gráficos y pruebas estadísticas.

#	Pregunta	Cómo la respondimos	Respuesta
P1	¿Qué distingue a los clientes que más gastan?	Prueba de Kruskal-Wallis del gasto por cada variable; control por estrato	Solo el estrato. La membresía premium parecía influir, pero dentro de cada estrato no cambia el gasto.
P2	¿La preferencia alimenticia se relaciona con el estrato?	Tabla cruzada, chi-cuadrado y V de Cramér	No: son independientes ($p = 0,90$; $V = 0,026$).
P3	¿Qué variables están relacionadas entre sí?	Mapa de V de Cramér entre todas las variables categóricas	Solo estrato y membresía (0,76) y edad y licor (0,34).
P4	¿Quién consume licor?	Consumo por grupo de edad, edad por edad y por estrato	Depende de la edad: 90% entre 18 y 30 años; por estrato es igual. La campaña se dirige a mayores de 21 (edad legal en EE. UU.).
P5	¿La oferta cubre lo que los clientes prefieren comer?	Demanda contra oferta por grupo de preferencia (base unificada)	No para vegetarianos y veganos: 847 clientes por restaurante.
P6	¿La oferta cubre lo que los clientes pueden pagar?	Gasto por visita contra rangos de precio de Yelp	Brecha en lo económico: el 28% de los clientes que visitan gasta hasta \$10 y solo el 0,7% de los restaurantes es \$.

#	Pregunta	Cómo la respondimos	Respuesta
P7	¿Cómo segmentamos por valor?	Índice de valor (gasto × frecuencia) y cuartiles	4 segmentos; Alto valor (24%) genera el 66% del valor.
P8	¿Dónde está el potencial de crecimiento?	Cruce de gasto y frecuencia en las medianas; escenario simulado	957 ocasionales de alto gasto: hasta +11,6% del valor si visitaran más.

La sección 9 del notebook resume los hallazgos y las 9 recomendaciones, cada una con el gráfico que la respalda, y la sección 10 explica las limitaciones. El detalle de cada recomendación (a quién está dirigida, cómo implementarla y cómo medirla) está en Recomendaciones.pdf.


8. Resultados principales



Cientes por ciudad (Avance_EDA.ipynb, sección 3): Chicago es la ciudad con más clientes.



Mapa de asociaciones entre variables (Avance_EDA.ipynb, P3): solo estrato y membresía, y edad y licor, se relacionan.



Clientes por restaurante afín de Yelp (Avance_API_Yelp.ipynb, sección 6.7).

#	Hallazgo	Evidencia
1	La preferencia alimenticia y el estrato no se relacionan.	V de Cramér = 0,026; chi-cuadrado p = 0,90. Todos los estratos tienen casi la misma mezcla de preferencias.

#	Hallazgo	Evidencia
2	El 24% de los clientes genera el 66% del valor.	Segmento Alto valor: 1.281 clientes, ingreso medio de \$10.247, 85% con membresía premium.
3	El valor lo define el estrato; la membresía premium solo lo refleja.	Mediana de gasto por visita: \$6,86 (Bajo), \$17,65 (Medio), \$32,61 (Alto), \$53,09 (Muy Alto). Dentro de cada estrato premium y no premium gastan igual ($p = 0,68; 0,83; 0,23$).
4	Vegetarianos y veganos: el mayor grupo, casi sin oferta.	31,5% de los clientes vs. 2 de 240 restaurantes (0,8%): 847 clientes por restaurante.
5	Brecha de precio.	El 28% de los clientes que visitan gasta hasta \$10 por visita; solo 1 de los 144 restaurantes con precio (0,7%) es \$.
6	El licor depende de la edad, no del estrato.	90% de consumo entre 18 y 30 años vs. 55% en los demás ($V = 0,34$); por estrato, 62-63% en todos ($p = 0,69$).
7	Potencial de crecimiento en los ocasionales de alto gasto.	957 clientes que gastan \$33 por visita pero visitan 3,6 veces (embajadores: 6,4). Igualar esa frecuencia sumaría ~12% al valor.
8	"Joyas ocultas" en Yelp.	El rating baja al subir las reseñas (correlación de -0,38, con las reseñas en escala logarítmica); 24 restaurantes con rating de 4,6 o más y poca visibilidad.
9	Género, medio de pago y ocio no se relacionan con nada.	V de Cramér menor a 0,05 con todas las demás variables.
10	1 de cada 4 clientes no se puede contactar.	1.359 clientes (25%) sin correo ni teléfono, en proporción parecida en todos los segmentos.

De los hallazgos a las recomendaciones

Recomendación	Se apoya en
1. Retener al segmento Alto valor	Hallazgo 2
2. Aumentar la frecuencia de los ocasionales de alto gasto	Hallazgo 7
3. Oferta vegetariana y vegana para Alto valor	Hallazgos 1, 2 y 4
4. Campañas de bares por edad (21 a 30 años)	Hallazgo 6
5. Ofertas accesibles para Bajo valor e Inactivos	Hallazgos 3 y 5
6. Promocionar las joyas ocultas	Hallazgo 8
7. Probar la membresía premium con un test A/B	Hallazgo 3
8. Promociones canjeables en el local	Hallazgo 9 (efectivo 39%)

Recomendación	Se apoya en
9. Completar el contacto y mejorar la calidad de los datos	Hallazgo 10 y limpieza del Avance 1

9. Decisiones y supuestos

- **Una sola ciudad (Chicago):** las campañas son locales y es la ciudad con más clientes.
- **Mediana en lugar de media** para imputar: gasto e ingresos son asimétricos.
- **No se eliminaron outliers de gasto e ingresos:** son clientes reales de alto valor.
- **Cruce clientes-Yelp por tipo de comida:** no hay un identificador común, así que es una aproximación.
- **Índice de valor = gasto × frecuencia:** es relativo (no conocemos la unidad de la frecuencia); sirve para ordenar clientes pero no equivale a dólares.
- **Segmentos por cuartiles del índice** entre los clientes activos (25% superior, 50% medio, 25% inferior) y los que no visitan aparte.
- **Rangos de precio de Yelp** usados como referencia: \$ hasta 10 USD, \$\$ de 11 a 30, \$\$\$ de 31 a 60, \$\$\$\$ más de 60 (aproximados).
- **Joyas ocultas:** rating de 4,6 o más, al menos 30 reseñas (para que la nota sea confiable) y menos reseñas que la mediana.
- **Descarga de Yelp fija:** el análisis usa la descarga guardada del 24/09/2026 para que los resultados no cambien cada vez que Yelp actualiza su ranking.
- **Clave de la API en un archivo .env:** así la clave no queda escrita en el código ni publicada en GitHub.

10. Limitaciones

- Los 240 restaurantes son el 3% de los 7.900 que Yelp registra para la búsqueda, ordenados por relevancia: favorecen a los locales populares y subrepresentan a los baratos (solo 1 figura como \$).
- Las categorías de Yelp describen el negocio, no el menú, y los rangos de precio son aproximados.
- Se asume que los clientes comen en la ciudad donde viven.
- 1 de cada 4 clientes no tiene correo ni teléfono: las acciones directas no les llegan hasta que se completen sus datos.
- Los datos de clientes son sintéticos (provistos por el curso): algunas relaciones son más limpias que en datos reales (por ejemplo, el salto del consumo de licor entre los 30 y 31 años).
- El escenario de crecimiento es una simulación, no una predicción.
- Se probaron muchas relaciones a la vez, así que alguna podría salir por azar; las que destacamos están muy lejos de ese límite.

11. Extra credits

- **Técnicas estadísticas:** pruebas de Kruskal-Wallis y chi-cuadrado, V de Cramér y mapa de asociaciones entre todas las variables categóricas,

control por estrato para separar el efecto de la membresía, análisis de sensibilidad de la definición vegetariana y escenario de crecimiento.

- **Automatización y organización del código:** la ciudad (CIUDAD) se define en un solo lugar y la clave de Yelp se guarda aparte en un archivo .env (con .env.example como modelo y .gitignore para no subirla); la descarga de Yelp (descargar_negocios) y la V de Cramér (cramer_v) son funciones reutilizables; cada notebook corre completo de arriba hacia abajo sin pasos manuales, y el de Yelp guarda la base unificada en CSV para el Avance 3.

12. Cumplimiento de la consigna

Pedido de la consigna	Dónde se cumple
Repositorio público ProyectoM1_NombreEstudiante	ProyectoM1_TomasBabot en GitHub
Cargar y explorar la base de clientes	Avance_EDA.ipynb, sección 2
Filtrar por una ciudad y justificar el criterio	Avance_EDA.ipynb, sección 3
Identificar y tratar nulos, duplicados y errores	Avance_EDA.ipynb, sección 4
Tablas de género, preferencias y consumo de licor	Avance_EDA.ipynb, sección 5
Análisis exploratorio con gráficos	Avance_EDA.ipynb, secciones 6 y 7
Conectarse a la API de Yelp y extraer nombre, categoría, rating y reseñas	Avance_API_Yelp.ipynb, secciones 2 a 5
Manejo de autenticación con claves API	Archivo .env, .env.example y .gitignore (Avance_API_Yelp.ipynb, sección 1)
Integrar Yelp al análisis de la ciudad	Avance_API_Yelp.ipynb, sección 6 (base unificada)
Preguntas de negocio con visualizaciones	Avance_EDA.ipynb, sección 8 (P1 a P8)
Recomendaciones basadas en los hallazgos	Avance_EDA.ipynb, sección 9, y Recomendaciones.pdf
README con pasos y resultados	Este documento

13. Glosario

Término	Qué significa
Mediana	El valor del medio cuando se ordenan los datos. A diferencia de la media, no la mueven los valores extremos.
p-valor	Probabilidad de ver una diferencia así solo por azar. Si es menor a 0,05, consideramos que la diferencia es real (significativa).

Término	Qué significa
Chi-cuadrado	Prueba que indica si dos variables categóricas están relacionadas.
V de Cramér	Mide qué tan fuerte es la relación entre dos variables categóricas, de 0 (ninguna) a 1 (perfecta).
Kruskal-Wallis	Prueba que compara un valor numérico (por ejemplo, el gasto) entre dos o más grupos sin exigir que tenga forma de campana.
Índice de valor	Gasto por visita multiplicado por la frecuencia de visita. Ordena a los clientes según cuánto aportan.
Índice de cobertura	Porcentaje de restaurantes de un grupo dividido por el porcentaje de clientes de ese grupo. Menos de 1 significa que la oferta no alcanza.
Left join	Unión de tablas que conserva todas las filas de la tabla principal (los clientes) y les agrega los datos de la otra cuando existen.
.env	Archivo de texto con datos secretos (como la clave de una API) que se usa en la computadora propia y no se sube a GitHub.
.gitignore	Lista de archivos que git ignora y no sube al repositorio.