

Proyecto Integrador M1 · Conociendo al cliente 360°

Estudiante: Tomás Babot

Programa: Data Science, Soy Henry (cohorte DSPT12)

Ciudad analizada: Chicago

Repositorio: github.com/babottomas561-cell/ProyectoM1_TomasBabot

Los términos técnicos (índice de valor, segmentos, mediana, p-valor, etc.) se explican en detalle, con ejemplos, en la sección 4, y el glosario de la sección 14 los resume.

Índice

1. Resumen del proyecto
2. Estructura del repositorio
3. Datos utilizados
4. Conceptos clave: qué medimos y cómo
5. Cómo reproducir el análisis
6. Avance 1 · Carga, filtrado, limpieza y tabulación
7. Avance 2 · API de Yelp e integración
8. Avance 3 · Análisis, interpretación y recomendaciones
9. Resultados principales
10. Decisiones y supuestos
11. Limitaciones
12. Extra credits
13. Cumplimiento de la consigna
14. Glosario

1. Resumen del proyecto

Contexto

InsightReach es una empresa de marketing digital que diseña campañas personalizadas para negocios locales. Con el crecimiento de su base de clientes quiere segmentarlos mejor para que sus campañas sean más efectivas. Para eso recibimos una base de 30.000 clientes de restaurantes de 10 ciudades de EE. UU., en el rol de Científico de Datos Junior.

Objetivo

Limpiar y explorar la base de clientes, enriquecerla con datos de mercado obtenidos de la API de Yelp y convertir el análisis en recomendaciones de segmentación que el equipo comercial pueda aplicar.

Alcance

El análisis se enfoca en Chicago: 5.384 clientes (la ciudad más grande de la base) y 240 restaurantes de Yelp. Además de describir a los clientes, buscamos responder preguntas de negocio: qué distingue a quienes más gastan, si la preferencia alimenticia depende del estrato, si la oferta de la ciudad cubre lo que

los clientes quieren comer y pueden pagar, y dónde está el potencial de crecimiento.

Resultado en pocas líneas

- El valor de un cliente lo define su nivel socioeconómico; la preferencia alimenticia es independiente. Por eso proponemos segmentar en dos ejes: el estrato para decidir cuánto invertir y la preferencia para decidir qué ofrecer.
- El 24% de los clientes genera el 66% del valor. Es el segmento Alto valor: el cuarto de los clientes que más gasta en restaurantes si se suman todas sus visitas (ver la sección 4).
- El grupo vegetariano y vegano es el más grande (31,5%) y casi no tiene oferta en Yelp (2 de 240 restaurantes).
- Hay 853 clientes con presupuesto que visitan poco: si visitaran como los mejores clientes, el valor total subiría cerca de un 10%.
- Las 9 recomendaciones, con su plan de implementación, están en Recomendaciones.pdf.

2. Estructura del repositorio

El repositorio tiene tres carpetas y tres archivos de configuración:

Carpeta	Archivo	Qué contiene
Avances/	Avance_EDA.ipynb	Avance 1 (carga, limpieza, tablas y EDA, secciones 1 a 7) y Avance 3 (análisis y recomendaciones, secciones 8 a 10)
Avances/	Avance_API_Yelp.ipynb	Avance 2 (conexión a la API de Yelp e integración con los clientes)
Documentacion/	README.pdf	Este documento: pasos, resultados y decisiones
Documentacion/	Recomendaciones.pdf	Propuestas de segmentación para el equipo comercial
data/	base_datos_restaurantes_USA_v2.csv	Base original de clientes (provista por el curso)
data/	clientes_chicago_limpios.csv	Clientes de Chicago limpios (salida del Avance 1, entrada del Avance 2)

Carpeta	Archivo	Qué contiene
data/	yelp_restaurantes_chicago.csv	Restaurantes de Chicago descargados de la API de Yelp
data/	base_unificada_chicago.csv	Cientes de Chicago limpios más la información de Yelp (salida del Avance 2)
(carpeta principal)	.env.example	Modelo para configurar la clave de Yelp (sin la clave)
(carpeta principal)	.gitignore	Lista de archivos que git no sube, entre ellos el .env con la clave
(carpeta principal)	requirements.txt	Librerías necesarias y sus versiones

Los dos notebooks tienen la misma estructura en cada paso: qué hacemos y por qué, el código, el resultado y una interpretación.

3. Datos utilizados

Base de clientes (provista por el curso)

30.000 clientes y 17 columnas. Las variables que usamos en el análisis son:

Variable	Tipo	Significado
id_persona	Identificador	Código único del cliente
edad	Numérica	Edad en años
genero	Categórica	Femenino o Masculino
ciudad_residencia	Categórica	Una de las 10 ciudades de la base
estrato_socioeconomico	Categórica ordinal	Bajo, Medio, Alto o Muy Alto
frecuencia_visita	Numérica	Cantidad de visitas a restaurantes (escala de 0 a 10)
promedio_gasto_comida	Numérica	Gasto promedio por visita (USD)
ingresos_mensuales	Numérica	Ingreso mensual (USD)
preferencias_alimenticias	Categórica	Carnes, Mariscos, Pescado, Vegetariano, Vegano u Otro
consume_licor, ocio, membresia_premium	Categóricas (Sí/No)	Hábitos y suscripción

Variable	Tipo	Significado
tipo_de_pago_mas_usado	Categórica	Efectivo, Tarjeta, App o Criptomoneda

Las otras cuatro columnas (nombre, apellido, teléfono y correo) son datos personales que no aportan al análisis y se eliminaron de la base de trabajo.

Restaurantes de Yelp (API)

240 restaurantes de Chicago descargados el 24/09/2026 del endpoint businesses/search de Yelp Fusion. Para cada uno guardamos 13 columnas: identificador, nombre, rating, cantidad de reseñas, precio, ciudad, código postal, latitud, longitud, categorías (en texto y en códigos de Yelp), si hace delivery y si está cerrado.

Clientes limpios (salida del Avance 1)

Los 5.384 clientes de Chicago después de la limpieza: sin nulos, con valores válidos y sin datos personales (13 columnas). Se guardan en data/clientes_chicago_limpios.csv.

Base unificada (salida del Avance 2)

Los 5.384 clientes limpios de Chicago con 18 columnas: las 13 de la base de trabajo, el grupo de preferencia y 4 columnas de Yelp sobre la oferta afín a su preferencia (cantidad de restaurantes, rating promedio, clientes por restaurante e índice de cobertura).

4. Conceptos clave: qué medimos y cómo

Esta sección explica, con ejemplos, cada métrica y cada grupo de clientes que usamos en el análisis y en las recomendaciones. Para cada uno se indica qué es, cómo se calcula, por qué lo usamos y dónde está en los notebooks.

4.1 Media y mediana

La **media** es el promedio. La **mediana** es el valor del medio: si ordenamos a todos los clientes de menor a mayor, la mitad queda por encima y la otra mitad por debajo. La diferencia importa cuando hay unos pocos valores muy altos, porque la media se va hacia ellos y la mediana no. En Chicago, el gasto por visita tiene una media de \$25,53 y una mediana de \$19,06: unos pocos clientes que gastan mucho suben el promedio, pero el cliente típico gasta alrededor de \$19.

Por qué la usamos: gasto e ingresos tienen valores muy altos poco frecuentes, así que para describir al cliente típico y para completar datos faltantes usamos la mediana. **Dónde:** Avance_EDA.ipynb, secciones 4.4 y 6.

4.2 Estrato socioeconómico

Es el nivel socioeconómico de cada cliente según la base: Bajo, Medio, Alto o Muy Alto. Resultó ser la variable más importante del análisis, porque explica casi todo el comportamiento de gasto: la mediana de gasto por visita va de \$6,84 en el estrato Bajo a \$53,11 en el Muy Alto, y la frecuencia típica de visita va de 2 a 7 veces. Por eso lo usamos para completar la frecuencia y el gasto faltantes (ver la sección 6.3) y para decidir cuánto invertir en cada cliente.

4.3 Índice de valor

Qué es: una medida de cuánto vale cada cliente. Se calcula como:

índice de valor = gasto promedio por visita × frecuencia de visita

Por qué así: para saber cuánto vale un cliente no alcanza con mirar cuánto gasta en cada visita; también importa cuántas veces visita. Un cliente que gasta mucho pero casi nunca sale vale menos que uno que gasta un poco menos pero sale seguido. Multiplicar las dos cosas aproxima cuánto gasta el cliente en restaurantes en total.

Cliente	Gasto por visita	Visitas	Índice de valor
A	\$20	5	$20 \times 5 = 100$
B	\$60	2	$60 \times 2 = 120$
C	\$8	3	$8 \times 3 = 24$

El cliente B gasta tres veces más por visita que A, pero como visita menos, su valor total es parecido. **Limitación:** es un índice relativo, no un monto en dólares, porque la base no dice en qué período se cuentan las visitas (por semana, por mes o por año). Sirve para ordenar a los clientes de más a menos valioso. **Dónde:** Avance_EDA.ipynb, P7.

4.4 Segmentos de valor: Alto valor, Valor medio, Bajo valor e Inactivo

Cómo se arman:

1. Primero se separa a los 261 clientes que no visitan restaurantes (frecuencia 0). Son el segmento **Inactivo**.
2. A los otros 5.123, los **clientes activos**, se los ordena por su índice de valor, de mayor a menor.
3. Esa lista se divide en cuartos, es decir, en cuatro grupos del mismo tamaño. El cuarto de arriba es **Alto valor**, los dos cuartos del medio son **Valor medio** y el cuarto de abajo es **Bajo valor**.

Por qué en cuartos: es una forma simple y estándar de separar a los mejores clientes del resto con grupos de tamaño parecido, y no depende de elegir un número arbitrario. Con los datos de Chicago, los cortes quedan así:

Segmento	Regla	Ejemplo de cliente	Clientes	% del valor
Alto valor	Índice de 192,7 o más	\$40 por visita y 5 visitas (200)	1.281 (24%)	66%
Valor medio	Índice entre 31,1 y 192,7	\$20 por visita y 4 visitas (80)	2.561 (48%)	31%
Bajo valor	Índice de 31,1 o menos	\$8 por visita y 3 visitas (24)	1.281 (24%)	3%
Inactivo	No visita restaurantes	Frecuencia 0 y gasto 0	261 (5%)	0%

El "% del valor" es la parte de la suma de todos los índices que aporta cada segmento: el cuarto de clientes de Alto valor aporta dos tercios del total. **Cómo son:** Alto valor es de estratos Muy Alto (56%) y Alto (44%), con un ingreso medio de \$10.288 y 86% de membresía premium; Bajo valor es sobre todo de estrato Bajo (69%), con un ingreso medio de \$1.787; los Inactivos son todos de estrato Bajo. **Dónde:** Avance_EDA.ipynb, P7.

4.5 Tipos de cliente activo: embajadores, ocasionales, frecuentes y distantes

El índice de valor junta dos cosas que conviene mirar por separado: cuánto gasta el cliente en cada visita y cuántas veces visita. Para separarlas usamos la mediana de cada una entre los clientes activos: la mitad gasta más de \$20,30 por visita y la mitad visita más de 4 veces. Combinando las dos aparecen cuatro tipos:

Tipo	Regla	Clientes	Qué significa
Embajadores	Más de \$20,30 por visita y más de 4 visitas	1.708	Los mejores clientes: gastan y vuelven. Generan el 73% del valor.
Ocasionales de alto gasto	Más de \$20,30 por visita y 4 visitas o menos	853	Tienen presupuesto, pero vienen poco. Es donde más se puede crecer.
Frecuentes de bajo gasto	\$20,30 o menos por visita y más de 4 visitas	696	Vienen seguido, pero gastan poco en cada visita.
Distantes	\$20,30 o menos y 4 visitas o menos	1.866	Gastan poco y vienen poco.

Es una segunda mirada sobre los mismos clientes activos, no un reemplazo de los segmentos de valor: un cliente puede ser de Valor medio y a la vez ocasional de alto gasto (de los 853 ocasionales, 743 son de Valor medio y 110 de Alto valor).

Escenario de crecimiento: para estimar cuánto podrían aportar los ocasionales simulamos dos casos, suponiendo que cada uno mantiene su gasto por visita. Si cada ocasional visitara una vez más, el valor total subiría un 3,6% (se suma una vez el gasto por visita de cada uno). Si visitaran tanto como los embajadores (6,3 veces en promedio), subiría un 9,8%. Es una simulación, no una predicción.

Dónde: Avance_EDA.ipynb, P8.

4.6 Grupos de preferencia, clientes por restaurante e índice de cobertura

Para comparar lo que piden los clientes con lo que ofrece Yelp, agrupamos las preferencias de los clientes y las categorías de los restaurantes en 4 grupos comunes: Carnes, Mariscos y pescado, Vegetariano/Vegano y Otro (sección 7.3). Para cada grupo calculamos dos medidas:

- **Clientes por restaurante:** cantidad de clientes del grupo dividida por la cantidad de restaurantes afines. Cuanto más alto, menos oferta tiene cada cliente. Vegetariano/Vegano: 1.694 clientes / 2 restaurantes = 847.
- **Índice de cobertura:** el % de restaurantes del grupo dividido por el % de clientes del grupo. Un valor de 1 significa que la oferta acompaña a la demanda; menos de 1, que falta oferta. Vegetariano/Vegano: 0,8% de los

restaurantes / 31,5% de los clientes = 0,03, es decir, la oferta es unas 30 veces menor que la demanda. Carnes: 13,3% / 29,5% = 0,45.

Dónde: Avance_API_Yelp.ipynb, secciones 6.2 y 6.3, y Avance_EDA.ipynb, P5.

4.7 Rangos de precio y brecha de precio

Yelp clasifica cada restaurante con signos de pesos según lo que cuesta comer ahí. Como referencia usamos: \$ hasta 10 USD, \$\$ de 11 a 30, \$\$\$ de 31 a 60 y \$\$\$\$ más de 60 (son aproximados). A cada cliente que visita lo ubicamos en el rango que corresponde a su gasto por visita y comparamos esa distribución con la de los restaurantes. La **brecha de precio** es la diferencia entre las dos: el 28% de los clientes que visitan gasta hasta \$10 (rango \$), pero solo el 0,7% de los restaurantes que informan precio está en ese rango. **Dónde:** Avance_EDA.ipynb, P6.

4.8 Joyas ocultas

Son restaurantes de Yelp muy bien calificados y poco conocidos. Para que un restaurante sea "joya oculta" tiene que cumplir tres condiciones: rating de 4,6 o más; al menos 30 reseñas, para que la nota sea confiable (un 5,0 con 3 reseñas no dice mucho); y menos reseñas que la mediana (234), es decir, estar en la mitad menos conocida. Cumplen las tres 24 restaurantes, por ejemplo Tepalcates (4,9 de rating y 147 reseñas). **Por qué importan:** en Yelp los locales más populares no son los mejor calificados (correlación de -0,38 entre rating y reseñas), así que estos restaurantes son una buena oferta para promocionar. **Dónde:** Avance_API_Yelp.ipynb, sección 5.4.

4.9 Pruebas estadísticas

Usamos pruebas estadísticas para saber si una diferencia que vemos en los datos es real o podría deberse al azar.

Prueba o medida	Para qué sirve	Cómo se lee	Ejemplo del análisis
p-valor	Lo devuelven las pruebas: es la probabilidad de ver una diferencia así solo por azar.	Menos de 0,05: la diferencia es real (significativa). Más de 0,05: puede ser azar.	Gasto según género: $p = 0,64$, no hay diferencia real.
Kruskal-Wallis	Comparar un valor numérico (como el gasto) entre dos o más grupos, sin exigir que tenga forma de campana.	Se mira su p-valor.	Gasto según estrato: $p < 0,0001$, la diferencia es real (P1).
Chi-cuadrado	Saber si dos variables categóricas están relacionadas.	Se mira su p-valor.	Preferencia y estrato: $p = 0,90$, no están relacionadas (P2).

Prueba o medida	Para qué sirve	Cómo se lee	Ejemplo del análisis
V de Cramér	Medir qué tan fuerte es la relación entre dos variables categóricas.	De 0 (ninguna) a 1 (perfecta): menos de 0,1 despreciable, 0,1 a 0,3 débil, 0,3 a 0,5 moderada, más de 0,5 fuerte.	Estrato y membresía: 0,76, fuerte (P3).
Correlación	Medir si dos variables numéricas suben o bajan juntas.	De -1 (relación inversa) a 1 (relación directa); cerca de 0, sin relación lineal.	Ingreso y frecuencia de visita: 0,77 (Avance_EDA.ipynb, sección 7.4).

Control por estrato: cuando dos variables dependen del estrato, comparar sin más puede engañar. A primera vista los clientes premium gastan más, pero al comparar premium y no premium dentro del mismo estrato el gasto es casi igual ($p = 0,68$ en Medio, $0,88$ en Alto y $0,22$ en Muy Alto). La membresía no aumenta el gasto: solo refleja el estrato. **Dónde:** Avance_EDA.ipynb, P1 a P4.

4.10 Clientes contactables

Un cliente es contactable si tiene al menos un correo o un teléfono en la base. Correo y teléfono faltan en cerca del 50% de los casos cada uno, pero se complementan: 1.359 clientes (25%) no tienen ninguno de los dos y no se los puede contactar directamente. La proporción es parecida en todos los segmentos. Por eso las recomendaciones combinan el contacto directo con promociones en los restaurantes aliados. **Dónde:** Avance_EDA.ipynb, sección 4.1.

5. Cómo reproducir el análisis

1. Instalar las librerías: `pip install -r requirements.txt` (están pandas, numpy, matplotlib, seaborn, scipy, requests, python-dotenv y jupyter).
2. Abrir Jupyter y ejecutar los notebooks de la carpeta Avances/ de arriba hacia abajo (Run All).
3. Orden lógico: Avance 1 (Avance_EDA.ipynb, secciones 1 a 7), que guarda data/clientes_chicago_limpios.csv; Avance 2 (Avance_API_Yelp.ipynb), que cruza esos clientes con Yelp y guarda data/base_unificada_chicago.csv; y Avance 3 (Avance_EDA.ipynb, secciones 8 a 10), que parte de esa base unificada. Como todos estos archivos ya están guardados en data/, cada notebook también corre por separado.
4. API de Yelp (opcional): sin clave, el notebook lee data/yelp_restaurantes_chicago.csv, que tiene una respuesta real de la API guardada, así que todo se puede reproducir. Para consultar la API en vivo: copiar .env.example con el nombre .env y pegar la clave de Yelp después de `YELP_API_KEY=`. Para reemplazar la descarga guardada por una nueva, cambiar `ACTUALIZAR_CSV = True`.

Cómo se maneja la clave de la API

La clave de una API es como una contraseña: si se publica, cualquiera puede usarla a nuestro nombre. Por eso nunca se escribe en el código ni se sube a

GitHub. Se guarda en un archivo .env que queda solo en la computadora de quien corre el notebook, y el archivo .gitignore le indica a git que no lo suba. El notebook la carga con la librería python-dotenv (load_dotenv) y la lee con os.getenv('YELP_API_KEY'). El archivo .env.example muestra cómo configurarlo sin exponer ninguna clave.

Los dos notebooks se ejecutaron completos con Jupyter de arriba hacia abajo sin errores, con y sin el archivo .env.

6. Avance 1 · Carga, filtrado, limpieza y tabulación

Notebook: Avance_EDA.ipynb, secciones 1 a 7.

6.1 Carga y exploración

Cargamos el CSV con pandas y revisamos tamaño, tipos de dato y un resumen estadístico. A simple vista ya aparecían problemas de calidad: edades de -5 y 300 y frecuencias de visita negativas.

6.2 Filtrado por ciudad

Contamos los clientes por ciudad con groupby y elegimos **Chicago**, por dos motivos: es la ciudad con más clientes (5.384, el 17,9% de la base), lo que da muestras más grandes en cada segmento, y tiene mucha oferta en Yelp para el cruce del Avance 2. Las campañas de InsightReach son locales, así que tiene sentido analizar una ciudad a la vez.

6.3 Limpieza

Primero detectamos los problemas, después los tratamos con un criterio explícito y al final verificamos el resultado.

Problema	Qué encontramos	Decisión y justificación
Nulos en teléfono y correo	~50% de nulos	Se eliminan: no aportan al análisis y son datos personales.
Nulos en preferencia alimenticia	268 clientes (5%)	Pasan a la categoría Sin dato: no inventamos una preferencia.
Nulos en edad	23 clientes	Se imputan con la mediana general: no la mueven los valores extremos y la edad no depende del estrato.
Nulos en gasto	35 clientes	Se imputan con la mediana de su estrato, porque el gasto depende mucho del estrato.
Edades imposibles	29 clientes con -5 o 300	Pasan a nulo y se imputan con la mediana general.

Problema	Qué encontramos	Decisión y justificación
Frecuencias negativas	286 clientes con -3	Pasan a nulo y se imputan con la mediana de su estrato: la frecuencia típica va de 2 visitas en el estrato Bajo a 7 en el Muy Alto, y la mediana general (4) les asignaría visitas que no corresponden a su nivel.
Gasto igual a 0	261 clientes	Se conserva: son exactamente los 261 con frecuencia 0, clientes que no visitan.
Duplicados	Ninguna fila ni id repetido; 3 pares de homónimos; 14 correos repetidos	No se elimina nada: los homónimos son personas distintas y el correo no se usa.
Valores altos de gasto e ingresos	Aparecen como atípicos en los boxplots	Se conservan: son clientes reales de alto poder adquisitivo.
Cientes sin ningún dato de contacto	1.359 clientes (25%) sin correo ni teléfono	Se informa: no afecta el análisis, pero limita las campañas directas y se tiene en cuenta en las recomendaciones.

Resultado: una base sin nulos, con 5.384 clientes y 13 columnas, rangos válidos (edad entre 18 y 80, frecuencia entre 0 y 10) y tipos de dato correctos (edad y frecuencia pasan a enteros). Las medias casi no cambian, salvo la de frecuencia, que sube de 3,82 a 4,21 al desaparecer los -3. Todos los pasos están juntos en una función, `limpiar_clientes`, y la base limpia se guarda en `data/clientes_chicago_limpios.csv` para el Avance 2.

6.4 Tabulación y estadística descriptiva

- **Tablas de frecuencia** de género, preferencias alimenticias, consumo de licor, estrato, ocio, membresía y medio de pago. Por ejemplo: género 50/50, el 62,7% consume licor, y vegetarianos (20,9%) más veganos (10,6%) suman el 31,5%, el grupo de preferencia más grande.
- **Tablas cruzadas:** licor por estrato (62-63% en todos), preferencia por género (casi igual) y membresía por estrato (de 0,7% en Bajo a 95,3% en Muy Alto).
- **Estadística descriptiva:** media, mediana, moda, desvío, rango, asimetría, curtosis y coeficiente de variación. Gasto e ingresos son asimétricos a la derecha, por eso usamos la mediana para describir al cliente típico.
- **Visualizaciones:** histogramas, countplots, boxplots, mapa de correlación, scatterplot de ingresos contra gasto y comparación del gasto por estrato y por preferencia. Cada gráfico tiene su interpretación en el notebook.

7. Avance 2 · API de Yelp e integración

Notebook: Avance_API_Yelp.ipynb.

7.1 Conexión y extracción

Nos conectamos al endpoint `businesses/search` de Yelp Fusion con autenticación por token (encabezado `Authorization: Bearer`). La clave se lee de un archivo `.env` que no se sube al repositorio (ver la sección 5). Como Yelp devuelve 50 resultados por página, la función `descargar_negocios_pagina` con el parámetro `offset` hasta juntar 240 restaurantes. Cada pedido espera como máximo 10 segundos y, si Yelp responde con un error (por ejemplo, 401 por una clave inválida), el notebook se detiene con un mensaje claro. La respuesta es un JSON anidado, que aplanamos con `pd.json_normalize` para extraer nombre, categoría, rating, cantidad de reseñas, precio, ubicación, delivery y estado. La conexión en vivo devolvió el código 200 (correcto) en todas las páginas.

7.2 Control de calidad y exploración

- Sin duplicados, ratings válidos (entre 1 y 5) y ningún restaurante cerrado. El único faltante es el precio: 96 restaurantes (40%) no lo informan.
- Los ratings son altos y parejos (media de 4,38). La oferta se concentra en el rango \$\$ (93 restaurantes) y en bares: 103 restaurantes (43%) tienen una categoría de bar.
- Los más populares no son los mejor calificados: la correlación entre rating y reseñas es -0,38. Identificamos 24 "joyas ocultas": rating de 4,6 o más, al menos 30 reseñas y menos reseñas que la mediana.

7.3 Integración con los clientes

Las dos tablas no comparten un identificador (la base de clientes no dice a qué restaurante va cada uno), así que las cruzamos por un atributo común: el **tipo de comida**. Definimos 4 grupos que existen de los dos lados:

Grupo	Preferencias del cliente	Categorías de Yelp afines
Carnes	Carnes	Steakhouses, Barbeque, Burgers, Hot Dogs, Chicken Wings, Chicken Shop, Butcher
Mariscos y pescado	Mariscos, Pescado	Seafood, Sushi Bars, Fish & Chips, Poke
Vegetariano/Vegano	Vegetariano, Vegano	Vegetarian, Vegan
Otro	Otro	Los restaurantes que no encajan en los anteriores

Para cada grupo calculamos la oferta (restaurantes, rating promedio, clientes por restaurante e índice de cobertura) y la unimos a cada cliente con `pd.merge` (left join por grupo de preferencia). Los clientes se leen de la base limpia del Avance 1, así la limpieza no se repite. La base unificada conserva los 5.384 clientes, sin perder ni duplicar ninguno. Un análisis de sensibilidad con una definición vegetariana más amplia (que suma ensaladas, falafel y sin gluten) confirma el

hallazgo principal: la oferta pasa de 2 a 9 restaurantes, frente a un 31,5% de clientes.

8. Avance 3 · Análisis, interpretación y recomendaciones

Notebook: Avance_EDA.ipynb, secciones 8 a 10. Parte de la base unificada del Avance 2 y responde ocho preguntas de negocio con tablas, gráficos y pruebas estadísticas.


#	Pregunta	Cómo la respondimos	Respuesta
P1	¿Qué distingue a los clientes que más gastan?	Prueba de Kruskal-Wallis del gasto por cada variable; control por estrato	Solo el estrato. La membresía premium parecía influir, pero dentro de cada estrato no cambia el gasto.
P2	¿La preferencia alimenticia se relaciona con el estrato?	Tabla cruzada, chi-cuadrado y V de Cramér	No: son independientes ($p = 0,90$; $V = 0,026$).
P3	¿Qué variables están relacionadas entre sí?	Mapa de V de Cramér entre todas las variables categóricas	Solo estrato y membresía (0,76) y edad y licor (0,34).
P4	¿Quién consume licor?	Consumo por grupo de edad, edad por edad y por estrato	Depende de la edad: 90% entre 18 y 30 años; por estrato es igual. La campaña se dirige a mayores de 21 (edad legal en EE. UU.).
P5	¿La oferta cubre lo que los clientes prefieren comer?	Demanda contra oferta por grupo de preferencia (base unificada)	No para vegetarianos y veganos: 847 clientes por restaurante.
P6	¿La oferta cubre lo que los clientes pueden pagar?	Gasto por visita contra rangos de precio de Yelp	Brecha en lo económico: el 28% de los clientes que visitan gasta hasta \$10 y solo el 0,7% de los restaurantes es \$.
P7	¿Cómo segmentamos por valor?	Índice de valor (gasto $\times$ frecuencia) y cuartiles	4 segmentos; Alto valor (24%) genera el 66% del valor.
P8	¿Dónde está el potencial de crecimiento?	Cruce de gasto y frecuencia en las medianas; escenario simulado	853 ocasionales de alto gasto: hasta +9,8% del valor si visitaran más.

Las métricas y los segmentos que usan estas preguntas (índice de valor, segmentos de valor, tipos de cliente activo, índice de cobertura, joyas ocultas y

pruebas estadísticas) se explican en detalle, con ejemplos, en la sección 4.

La sección 9 del notebook resume los hallazgos y las 9 recomendaciones, cada una con el gráfico que la respalda, y la sección 10 explica las limitaciones. El detalle de cada recomendación (a quién está dirigida, cómo implementarla y cómo medirla) está en Recomendaciones.pdf.


9. Resultados principales



Cientes por ciudad (Avance_EDA.ipynb, sección 3): Chicago es la ciudad con más clientes.



Mapa de asociaciones entre variables (Avance_EDA.ipynb, P3): solo estrato y membresía, y edad y licor, se relacionan.



Clientes por restaurante afín de Yelp (Avance_API_Yelp.ipynb, sección 6.7).

#	Hallazgo	Evidencia
1	La preferencia alimenticia y el estrato no se relacionan.	V de Cramér = 0,026; chi-cuadrado p = 0,90. Todos los estratos tienen casi la misma mezcla de preferencias.

#	Hallazgo	Evidencia
2	El 24% de los clientes genera el 66% del valor.	Segmento Alto valor: 1.281 clientes, ingreso medio de \$10.288, 86% con membresía premium.
3	El valor lo define el estrato; la membresía premium solo lo refleja.	Mediana de gasto por visita: \$6,84 (Bajo), \$17,58 (Medio), \$32,96 (Alto), \$53,11 (Muy Alto). Dentro de cada estrato premium y no premium gastan igual ($p = 0,68; 0,88; 0,22$).
4	Vegetarianos y veganos: el mayor grupo, casi sin oferta.	31,5% de los clientes vs. 2 de 240 restaurantes (0,8%): 847 clientes por restaurante.
5	Brecha de precio.	El 28% de los clientes que visitan gasta hasta \$10 por visita; solo 1 de los 144 restaurantes con precio (0,7%) es \$.
6	El licor depende de la edad, no del estrato.	90% de consumo entre 18 y 30 años vs. 55% en los demás ($V = 0,34$); por estrato, 62-63% en todos ($p = 0,69$).
7	Potencial de crecimiento en los ocasionales de alto gasto.	853 clientes que gastan \$31 por visita pero visitan 3,5 veces (embajadores: 6,3). Igualar esa frecuencia sumaría ~10% al valor.
8	"Joyas ocultas" en Yelp.	El rating baja al subir las reseñas (correlación de -0,38, con las reseñas en escala logarítmica); 24 restaurantes con rating de 4,6 o más y poca visibilidad.
9	Género, medio de pago y ocio no se relacionan con nada.	V de Cramér menor a 0,05 con todas las demás variables.
10	1 de cada 4 clientes no se puede contactar.	1.359 clientes (25%) sin correo ni teléfono, en proporción parecida en todos los segmentos.

De los hallazgos a las recomendaciones

Recomendación	Se apoya en
1. Retener al segmento Alto valor	Hallazgo 2
2. Aumentar la frecuencia de los ocasionales de alto gasto	Hallazgo 7
3. Oferta vegetariana y vegana para Alto valor	Hallazgos 1, 2 y 4
4. Campañas de bares por edad (21 a 30 años)	Hallazgo 6
5. Ofertas accesibles para Bajo valor e Inactivos	Hallazgos 3 y 5
6. Promocionar las joyas ocultas	Hallazgo 8
7. Probar la membresía premium con un test A/B	Hallazgo 3
8. Promociones canjeables en el local	Hallazgo 9 (efectivo 39%)

Recomendación	Se apoya en
9. Completar el contacto y mejorar la calidad de los datos	Hallazgo 10 y limpieza del Avance 1

10. Decisiones y supuestos

- **Una sola ciudad (Chicago):** las campañas son locales y es la ciudad con más clientes.
- **Mediana en lugar de media para imputar, y por estrato para frecuencia y gasto:** gasto e ingresos son asimétricos, y la frecuencia y el gasto dependen mucho del estrato.
- **La limpieza se hace una sola vez:** el Avance 1 guarda la base limpia y el Avance 2 la lee, así los dos notebooks usan exactamente los mismos datos.
- **No se eliminaron outliers de gasto e ingresos:** son clientes reales de alto valor.
- **Cruce clientes-Yelp por tipo de comida:** no hay un identificador común, así que es una aproximación.
- **Índice de valor = gasto × frecuencia:** es relativo (no conocemos la unidad de la frecuencia); sirve para ordenar clientes pero no equivale a dólares.
- **Segmentos por cuartiles del índice** entre los clientes activos (25% superior, 50% medio, 25% inferior) y los que no visitan aparte.
- **Rangos de precio de Yelp** usados como referencia: \$ hasta 10 USD, \$\$ de 11 a 30, \$\$\$ de 31 a 60, \$\$\$\$ más de 60 (aproximados).
- **Joyas ocultas:** rating de 4,6 o más, al menos 30 reseñas (para que la nota sea confiable) y menos reseñas que la mediana.
- **Descarga de Yelp fija:** el análisis usa la descarga guardada del 24/09/2026 para que los resultados no cambien cada vez que Yelp actualiza su ranking.
- **Clave de la API en un archivo .env:** así la clave no queda escrita en el código ni publicada en GitHub.

11. Limitaciones

- Los 240 restaurantes son el 3% de los 7.900 que Yelp registra para la búsqueda, ordenados por relevancia: favorecen a los locales populares y subrepresentan a los baratos (solo 1 figura como \$).
- Las categorías de Yelp describen el negocio, no el menú, y los rangos de precio son aproximados.
- Se asume que los clientes comen en la ciudad donde viven.
- 1 de cada 4 clientes no tiene correo ni teléfono: las acciones directas no les llegan hasta que se completen sus datos.
- Los datos de clientes los provee el curso y parecen generados por reglas: algunas relaciones son más limpias que en datos reales (por ejemplo, el salto del consumo de licor entre los 30 y 31 años).
- El escenario de crecimiento es una simulación, no una predicción.
- Se probaron muchas relaciones a la vez, así que alguna podría salir por azar; las que destacamos están muy lejos de ese límite.

12. Extra credits

- **Técnicas estadísticas:** pruebas de Kruskal-Wallis y chi-cuadrado, V de Cramér y mapa de asociaciones entre todas las variables categóricas, control por estrato para separar el efecto de la membresía, análisis de sensibilidad de la definición vegetariana y escenario de crecimiento.
- **Automatización y organización del código:** la ciudad (CIUDAD) se define en un solo lugar y la clave de Yelp se guarda aparte en un archivo .env (con .env.example como modelo y .gitignore para no subirla); las tareas que se repiten son funciones reutilizables: limpiar_clientes (toda la limpieza), tabla_frecuencias y tabla_porcentajes (tablas), p_valor_kruskal y cramer_v (pruebas estadísticas) y descargar_negocios (API, con tiempo límite y manejo de errores). Los valores que se usan en todo el análisis (rutas, rangos de precio, nombres de los gráficos) se definen una sola vez. Los notebooks forman una cadena de archivos (base limpia → base unificada) y corren completos de arriba hacia abajo sin pasos manuales; requirements.txt fija las versiones de las librerías.

13. Cumplimiento de la consigna

Pedido de la consigna	Dónde se cumple
Repositorio público ProyectoM1_NombreEstudiante	ProyectoM1_TomasBabot en GitHub
Cargar y explorar la base de clientes	Avance_EDA.ipynb, sección 2
Filtrar por una ciudad y justificar el criterio	Avance_EDA.ipynb, sección 3
Identificar y tratar nulos, duplicados y errores	Avance_EDA.ipynb, sección 4
Tablas de género, preferencias y consumo de licor	Avance_EDA.ipynb, sección 5
Análisis exploratorio con gráficos	Avance_EDA.ipynb, secciones 6 y 7
Conectarse a la API de Yelp y extraer nombre, categoría, rating y reseñas	Avance_API_Yelp.ipynb, secciones 2 a 5
Manejo de autenticación con claves API	Archivo .env, .env.example y .gitignore (Avance_API_Yelp.ipynb, sección 1)
Integrar Yelp al análisis de la ciudad	Avance_API_Yelp.ipynb, sección 6 (base unificada)
Preguntas de negocio con visualizaciones	Avance_EDA.ipynb, sección 8 (P1 a P8)
Recomendaciones basadas en los hallazgos	Avance_EDA.ipynb, sección 9, y Recomendaciones.pdf
README con pasos y resultados	Este documento

14. Glosario

Término	Qué significa
Mediana	El valor del medio cuando se ordenan los datos. A diferencia de la media, no la mueven los valores extremos.
p-valor	Probabilidad de ver una diferencia así solo por azar. Si es menor a 0,05, consideramos que la diferencia es real (significativa).
Chi-cuadrado	Prueba que indica si dos variables categóricas están relacionadas.
V de Cramér	Mide qué tan fuerte es la relación entre dos variables categóricas, de 0 (ninguna) a 1 (perfecta).
Kruskal-Wallis	Prueba que compara un valor numérico (por ejemplo, el gasto) entre dos o más grupos sin exigir que tenga forma de campana.
Estrato socioeconómico	Nivel socioeconómico del cliente según la base: Bajo, Medio, Alto o Muy Alto.
Cliente activo	Cliente que visita restaurantes al menos una vez. Los que no visitan nunca son el segmento Inactivo.
Cuartos (cuartiles)	Cuatro grupos del mismo tamaño que se forman al ordenar los datos de menor a mayor.
Índice de valor	Gasto promedio por visita multiplicado por la cantidad de visitas. Aproxima cuánto gasta el cliente en total y ordena a los clientes según cuánto aportan. Ejemplo: \$20 por visita y 5 visitas = 100.
Alto valor, Valor medio y Bajo valor	Los clientes activos ordenados por su índice de valor: el 25% de arriba es Alto valor, el 50% del medio Valor medio y el 25% de abajo Bajo valor.
Embajadores, ocasionales de alto gasto, frecuentes de bajo gasto y distantes	Tipos de cliente activo según si gastan más o menos que la mediana por visita (\$20,30) y si visitan más o menos que la mediana (4 veces).
Joyas ocultas	Restaurantes de Yelp con rating de 4,6 o más, al menos 30 reseñas y menos reseñas que la mitad de los restaurantes: muy buenos y poco conocidos.
Grupo de control	Parte de los clientes que no recibe una acción, para comparar con quienes sí la reciben y saber si funcionó.
Índice de cobertura	Porcentaje de restaurantes de un grupo dividido por el porcentaje de clientes de ese grupo. Menos de 1 significa que la oferta no alcanza.

Término	Qué significa
Left join	Unión de tablas que conserva todas las filas de la tabla principal (los clientes) y les agrega los datos de la otra cuando existen.
.env	Archivo de texto con datos secretos (como la clave de una API) que se usa en la computadora propia y no se sube a GitHub.
.gitignore	Lista de archivos que git ignora y no sube al repositorio.